Санкт-Петербургский Национальный Исследовательский Университет Информационных Технологий, Механики и Оптики

ПИиКТ

Лабораторная работа 3

по дисциплине

«Информационные системы и базы данных»

Выполнил: Студент группы P33113

Мансуров Б.Б.

Преподаватель: Николаев В.В.

Санкт-Петербург

2020г

Задание

Составить запросы на языке SQL (пункты 1-2).

Для каждого запроса предложить индексы, добавление которых уменьшит время выполнения запроса (указать таблицы/атрибуты, для которых нужно добавить индексы, написать тип индекса; объяснить, почему добавление индекса будет полезным для данного запроса).

Для запросов 1-2 необходимо составить возможные планы выполнения запросов. Планы составляются на основании предположения, что в таблицах отсутствуют индексы. Из составленных планов необходимо выбрать оптимальный и объяснить свой выбор. Изменятся ли планы при добавлении индекса и как?

Для запросов 1-2 необходимо добавить в отчет вывод команды EXPLAIN ANALYZE [запрос]

Подробные ответы на все вышеперечисленные вопросы должны присутствовать в отчете (планы выполнения запросов должны быть нарисованы, ответы на вопросы - представлены в текстовом виде).

ЗАПРОС 1

```
-- 1. Сделать запрос для получения атрибутов из указанных таблиц, применив фильтры по указанным условиям:
-- Н_ТИПЫ_ВЕДОМОСТЕЙ, Н_ВЕДОМОСТИ.
-- Вывести атрибуты: Н_ТИПЫ_ВЕДОМОСТЕЙ.НАИМЕНОВАНИЕ, Н_ВЕДОМОСТИ.ИД.
-- Фильтры (AND):
-- a) Н_ТИПЫ_ВЕДОМОСТЕЙ.ИД <1.
-- b) Н_ВЕДОМОСТИ.ЧЛВК_ИД > 117219.
-- c) Н_ВЕДОМОСТИ.ЧЛВК_ИД = 153285.
-- Вид соединения: RIGHT JOIN.


SELECT ТИПЫ_ВЕДОМОСТЕЙ.НАИМЕНОВАНИЕ, ВЕДОМОСТИ.ИД
FROM Н_ТИПЫ_ВЕДОМОСТЕЙ AS ТИПЫ_ВЕДОМОСТЕЙ
        RIGHT JOIN Н_ВЕДОМОСТИ AS ВЕДОМОСТИ ON ТИПЫ_ВЕДОМОСТЕЙ.ИД = ВЕДОМОСТИ.ВЕД_ИД
WHERE ТИПЫ_ВЕДОМОСТЕЙ.ИД < 1
  AND ВЕДОМОСТИ.ЧЛВК_ИД > 117219
  AND ВЕДОМОСТИ.ЧЛВК_ИД = 153285;
```

Первое что мы можем сделать для оптимизации убрать ВЕДОМОСТИ.ЧЛВК_ИД > 117219. Потому что после этого у нас идет выборка по “=”, и в нашем случае лучше не делать лишний операции выборки. После изменений мы получим. Я проверил с помощью EXPLAIN ANALYZE.

```
SELECT ТИПЫ_ВЕДОМОСТЕЙ.НАИМЕНОВАНИЕ, ВЕДОМОСТИ.ИД
FROM Н_ТИПЫ_ВЕДОМОСТЕЙ AS ТИПЫ_ВЕДОМОСТЕЙ
        RIGHT JOIN Н_ВЕДОМОСТИ AS ВЕДОМОСТИ ON ТИПЫ_ВЕДОМОСТЕЙ.ИД = ВЕДОМОСТИ.ВЕД_ИД
WHERE ТИПЫ_ВЕДОМОСТЕЙ.ИД < 1
  AND ВЕДОМОСТИ.ЧЛВК_ИД = 153285;
```

ПЛАНЫ ВЫПОЛНЕНИЯ ЗАПРОСА

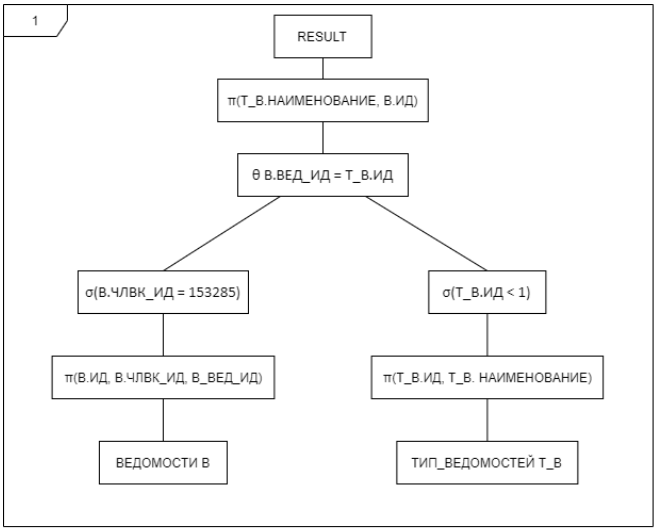

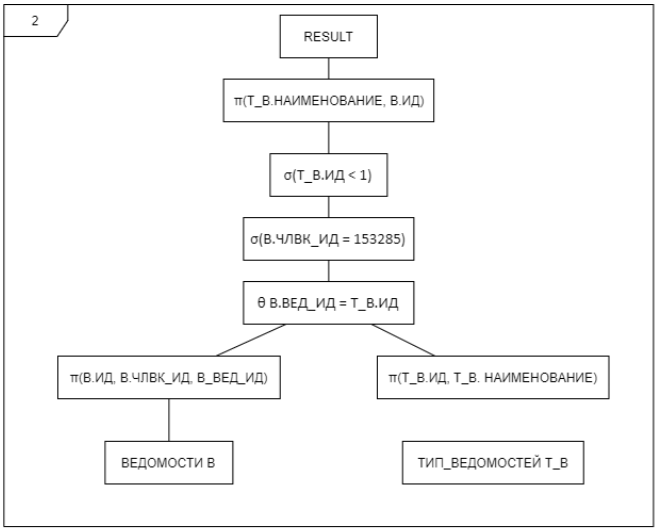

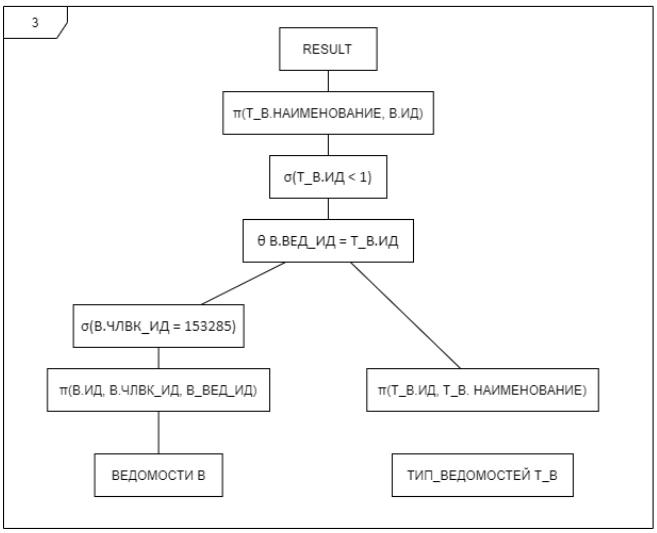

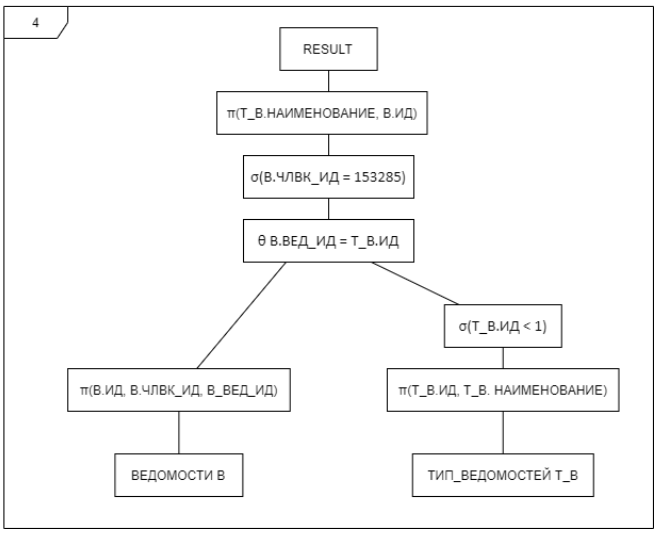

Чтобы оптимизировать запрос, необходимо делать выборку как можно раньше. Оптимальным является план номер 1. Если бы мы оставили H_ВЕДОМОСТИ.ЧЛВК_ИД > 117219. Имеет смысл сделать сначала выборку по H_ВЕДОМОСТЬ.ЧЛВК_ИД = 153285, а потом >, так как мы сильно сузим множество и не надо будет 2 раза по всем ЧЛВЕ_ИД.

ИНДЕКСЫ

T_B.ИД добавить индекса смысла нет, так как индексы неэффективны если в таблице мало строк (В таблице T_B 3 строк), и они будут занимать место.

На B.ЧЛВК_ИД имеет смысл добавить индекс. Если мы оставим H_ВЕДОМОСТИ.ЧЛВК_ИД > 117219 то нужно добавить B_TREE (дерево спускается по веткам на основе сравнений, и работает за log(глубина), а обычный поиск за линейное время), так как будет использоваться и =, и >.

Если мы не оставим H_ВЕДОМОСТИ.ЧЛВК_ИД > 11721 то лучше добавить HASH

Добавление

```
CREATE INDEX ИН_ВЕД_ЧЛВК_ИД ON "H_ВЕДОМОСТИ" USING btree ("ЧЛВК_ИД");
```

или

```
CREATE INDEX ИН_ВЕД_ЧЛВК_ИД ON "H_ВЕДОМОСТИ" USING hash ("ЧЛВК_ИД");
```

Этих индексов может ускорить запросы, потому что по данным атрибутам идет выборка с использованием операторов = и >.

EXPLAIN ANALYZE

```
QUERY PLAN
------------------------------------------------------------------------------------------------------------------------------------------------
 Nested Loop  (cost=0.42..197.94 rows=1 width=422) (actual time=0.024..0.024 rows=0 loops=1)
   Join Filter: ("ТИПЫ_ВЕДОМОСТЕЙ"."ИД" = "ВЕДОМОСТИ"."ВЕД_ИД")
   ->  Seq Scan on "Н_ТИПЫ_ВЕДОМОСТЕЙ" "ТИПЫ_ВЕДОМОСТЕЙ"  (cost=0.00..1.04 rows=1 width=422)
(actual time=0.023..0.023 rows=0 loops=1)
         Filter: ("ИД" < 1)
         Rows Removed by Filter: 3
   ->  Index Scan using "ВЕД_ЧЛВК_FK_IFK" on "Н_ВЕДОМОСТИ" "ВЕДОМОСТИ"  (cost=0.42..196.10
rows=64 width=8) (never executed)
         Index Cond: ("ЧЛВК_ИД" = 153285)
 Planning time: 0.204 ms
 Execution time: 0.060 ms
(9 rows)
```

Или

```
QUERY PLAN
------------------------------------------------------------------------------------------------------------------------------------------------
 Nested Loop  (cost=0.42..161.96 rows=1 width=422) (actual time=0.032..0.032 rows=0 loops=1)
   Join Filter: ("ТИПЫ_ВЕДОМОСТЕЙ"."ИД" = "ВЕДОМОСТИ"."ВЕД_ИД")
   ->  Seq Scan on "Н_ТИПЫ_ВЕДОМОСТЕЙ" "ТИПЫ_ВЕДОМОСТЕЙ"  (cost=0.00..1.04 rows=1 width=422)
(actual time=0.030..0.030 rows=0 loops=1)
         Filter: ("ИД" < 1)
         Rows Removed by Filter: 3
   ->  Index Scan using "ВЕД_ЧЛВК_FK_IFK" on "Н_ВЕДОМОСТИ" "ВЕДОМОСТИ"  (cost=0.42..160.28
rows=52 width=8) (never executed)
         Index Cond: (("ЧЛВК_ИД" > 117219) AND ("ЧЛВК_ИД" = 153285))
 Planning time: 0.381 ms
 Execution time: 0.095 ms
(9 rows)
```

ЗАПРОС 2

```
-- 2. Сделать запрос для получения атрибутов из указанных таблиц, применив фильтры по указанным условиям:
-- Таблицы: Н_ЛЮДИ, Н_ОБУЧЕНИЯ, Н_УЧЕНИКИ.
-- Вывести атрибуты: Н_ЛЮДИ.ИД, Н_ОБУЧЕНИЯ.НЗК, Н_УЧЕНИКИ.ГРУППА.
-- Фильтры: (AND)
-- a) Н_ЛЮДИ.ОТЧЕСТВО > Владимирович.
-- b) Н_ОБУЧЕНИЯ.НЗК < 933232.
-- Вид соединения: LEFT JOIN.


SELECT ЛЮДИ.ИД, ОБУЧЕНИЯ.НЗК, УЧЕНИКИ.ГРУППА
FROM Н_ЛЮДИ AS ЛЮДИ
	LEFT JOIN Н_ОБУЧЕНИЯ AS ОБУЧЕНИЯ ON ЛЮДИ.ИД = ОБУЧЕНИЯ.ЧЛВК_ИД
	LEFT JOIN Н_УЧЕНИКИ AS УЧЕНИКИ ON ЛЮДИ.ИД = УЧЕНИКИ.ЧЛВК_ИД
WHERE ЛЮДИ.ОТЧЕСТВО > 'Владимирович'
  AND ОБУЧЕНИЯ.НЗК < '933232';
```

ПЛАНЫ ВЫПОЛНЕНИЯ ЗАПРОСА

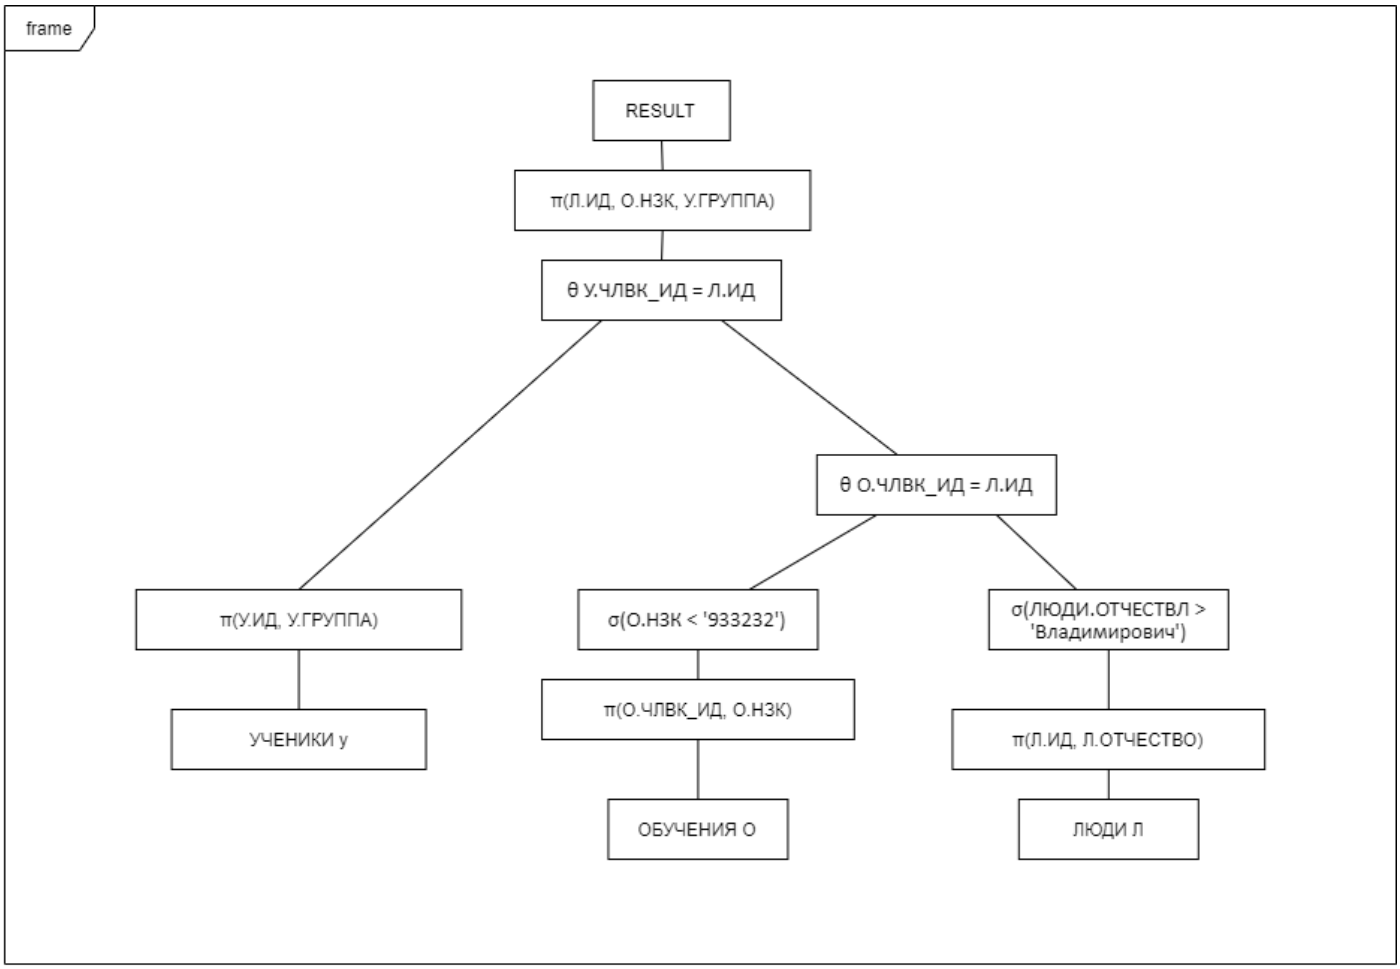

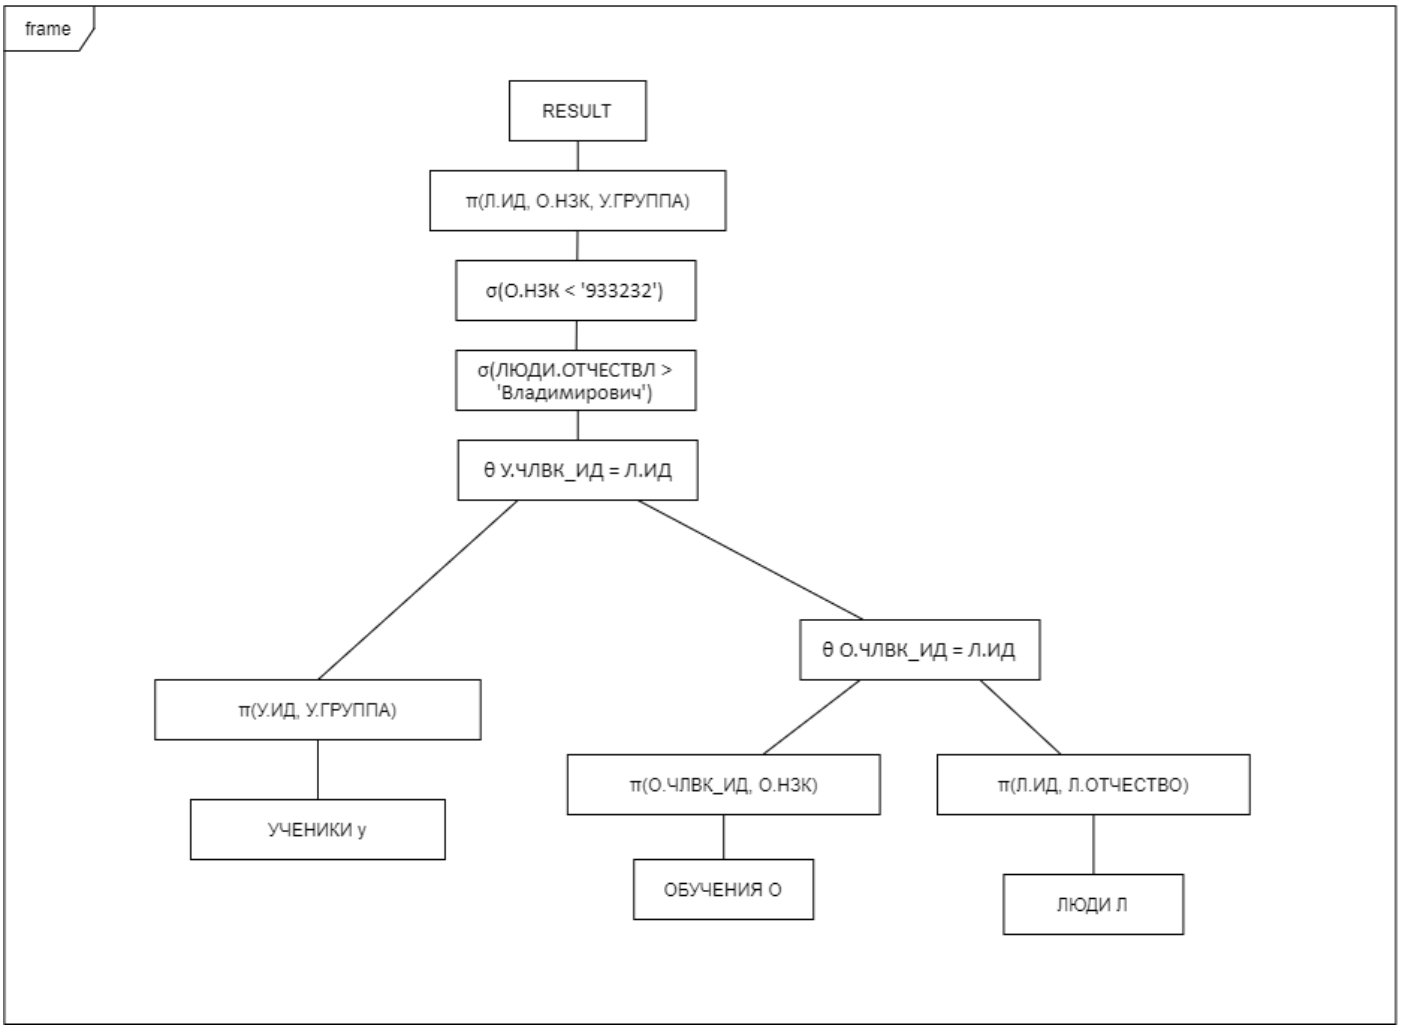

Второй план самый неоптимальный, так как операции выборки происходят после объединений. Оптимальным планом выполнения запроса является правый так как происходит объединение только после необходимой выборки, вместо полного объединения таблиц.

ИНДЕКСЫ

Имеет смысл добавить на ЛЮДИ.ИД HASH – индекс (хеширование значений идет по этому ключу, таким образом время выполнения +- константное), так как идет прямое сравнение и ЛЮДИ является правой таблицей в LEFT JOIN-е и по ней будет поиск.

Аналогичная ситуация с ОБУЧЕНИЯ.ЧЛВК_ИД происходит объединения — это тоже правая таблица в LEFT JOIN-а и по ней будет вестись поиск по конкретным значениям. Будем использовать HASH – индекс.

Нужно добавить BTREE –индекс на ЛЮДИ.ОТЧЕСТВО так как при выборку используется>

Аналогично нужно добавить BTREE – индекс на ОБУЧЕНИЯ.НЗК потому что у нас есть выборка связанное с>

```
CREATE INDEX ИН_ЛЮДИ_ИД ON "Н_ЛЮДИ" USING hash ("ИД");
CREATE INDEX ИН_ОБУЧ_ЧЛВК_ИД ON "Н_ОБУЧЕНИЯ" USING hash ("ЧЛВК_ИД");
CREATE INDEX ИН_ЛЮДИ_ОТЧЕСТВО ON "Н_ЛЮДИ" USING btree ("ОТЧЕСТВО");
CREATE INDEX ИН_ОБУЧ_НЗК ON "Н_ОБУЧЕНИЯ" USING btree ("НЗК");
```

Добавление этих индексов может здорово ускорить выполнения запросов, потому что по данным атрибутом идет выборка и соединение таблиц.

EXPLAIN ANALYZE

```
QUERY PLAN
------------------------------------------------------------------------------------------------------------------------------------------------
 Hash Right Join  (cost=365.53..1302.85 rows=7579 width=14) (actual time=8.617..26.901 rows=7226 loops=1)
   Hash Cond: ("УЧЕНИКИ"."ЧЛВК_ИД" = "ЛЮДИ"."ИД")
   ->  Seq Scan on "Н_УЧЕНИКИ" "УЧЕНИКИ"  (cost=0.00..774.11 rows=23311 width=8) (actual time=0.005..7.651 rows=23311 loops=1)
   ->  Hash  (cost=344.73..344.73 rows=1664 width=10) (actual time=8.597..8.597 rows=1676 loops=1)
         Buckets: 2048  Batches: 1  Memory Usage: 87kB
         ->  Hash Join  (cost=195.78..344.73 rows=1664 width=10) (actual time=4.184..7.992 rows=1676 loops=1)
               Hash Cond: ("ОБУЧЕНИЯ"."ЧЛВК_ИД" = "ЛЮДИ"."ИД")
               ->  Seq Scan on "Н_ОБУЧЕНИЯ" "ОБУЧЕНИЯ"  (cost=0.00..119.76 rows=3347 width=10) (actual time=0.015..2.145 rows=3347 loops=1)
                     Filter: (("НЗК")::text < '933232'::text)
                     Rows Removed by Filter: 1674
               ->  Hash  (cost=163.97..163.97 rows=2544 width=4) (actual time=4.126..4.126 rows=2546 loops=1)
                     Buckets: 4096  Batches: 1  Memory Usage: 122kB
                     ->  Seq Scan on "Н_ЛЮДИ" "ЛЮДИ"  (cost=0.00..163.97 rows=2544 width=4) (actual time=0.015..3.015 rows=2546 loops=1)
                           Filter: (("ОТЧЕСТВО")::text > 'Владимирович'::text)
                           Rows Removed by Filter: 2572
 Planning time: 0.505 ms
 Execution time: 28.729 ms
(17 rows)
```

ВЫВОД

Выполнив эту лабораторную работу я узнал много нового о возможностях PostgreSQL (SQL). Оказывается, если начать хорошо разбираться в вопросах оптимизации можно не хило поднят производительность если конечно все сделать грамотно. Это лабораторная работа открыла мне глаза.